universidad de las hespérides

Trabajo de Fin de Máster

Los límites del Aprendizaje por Refuerzo en Finanzas: Convergencia hacia Estrategias Equal-Weight en Carteras de ETFs

Universidad de las Hespérides
Máster Universitario en Economía
Autor: Fernando de Rojas Ojeda
Tutor: Santiago Calvo López
17/09/2025

Resumen

La presente investigación evalúa la capacidad del algoritmo Soft Actor-Critic (SAC) para superar estrategias pasivas equal-weight en optimización de carteras con ETFs sectoriales estadounidenses. Mediante validación multi-seed, se analizaron dos configuraciones de reward shaping: Una empleando únicamente Sharpe ratio y otra incorporando momentum con una ponderación 60/40. Los resultados revelan convergencia hacia estrategias equal-weight, con diferencias de Sharpe ratio microscópicas estadísticamente no significativas. El análisis walk-forward confirma estabilidad temporal con diferencias inapreciables y coeficientes de variación idénticos. Las curvas de valor acumulado se superponen completamente, mientras que el turnover nulo confirma convergencia hacia una diversificación naïve. Los hallazgos encontrados demuestran que, en contextos de alta correlación entre activos y señales débiles, algoritmos sofisticados de aprendizaje por refuerzo (RL) validan la optimalidad de estrategias pasivas. Este resultado contribuye a la literatura académica confirmando mediante RL contemporáneo principios fundamentales de eficiencia de mercados, sugiriendo que la convergencia hacia equal-weight indica ausencia de alpha explotable, y no limitaciones del algoritmo.

Palabras clave: Optimización de carteras, gestión pasiva, SAC, ETF, aqual-weight.

Abstract

This research evaluates the capacity of the Soft Actor-Critic (SAC) algorithm to outperform passive equal-weight strategies in portfolio optimization with US sectoral ETFs. Through multi-seed validation, two reward shaping configurations were analyzed: one employing solely Sharpe ratio and another incorporating momentum with a 60/40 weighting. The results reveal convergence toward equal-weight strategies, with microscopic Sharpe ratio differences that are statistically non-significant. Walk-forward analysis confirms temporal stability with negligible differences and identical coefficients of variation. Cumulative value curves overlap completely, while zero turnover confirms convergence to naïve diversification. The findings demonstrate that, in contexts characterized by high correlation between assets and weak signals, sophisticated reinforcement learning algorithms validate the optimality of passive strategies. This result contributes to the academic literature by confirming fundamental market efficiency principles through contemporary RL, suggesting that convergence toward equal-weight indicates absence of exploitable alpha rather than algorithm limitations.

Índice

1. Introducción 3

1.1 Planteamiento del problema 3

1.2 Objetivos y contribución 4

2. Marco teórico y antecedentes 4

2.1 Optimización de carteras y gestión pasiva 4

2.1.1 Los Exchange-Traded Funds como instrumentos de inversión diversificada . 5

2.2 Aprendizaje por refuerzo en finanzas 6

3. Metodología: Soft Actor Critic 8

3.1 Fundamentos teóricos de SAC 8

3.2 Arquitectura de SAC 9

3.3 Implementación técnica de SAC para trading 9

4. Diseño experimental 10

4.1 Datos y universo de inversión 10

4.2 Configuración del entorno de trading 11

4.3 Estrategias de reward shaping 11

5. Resultados principales 12

5.1 Validación multi-seed 12

5.2 Comparación directa con equal-weight 13

5.3 Análisis walk-forward 14

6. Interpretación de los resultados 14

6.1 Convergencia a estrategia pasiva 14

6.2 Implicaciones para el trading algorítmico 15

7. Limitaciones y trabajo futuro 16

8. Conclusiones 18

Bibliografía 20

ANEXO 23

1. Introducción

1.1 Planteamiento del problema

La gestión de carteras ha sido durante décadas objeto de un intenso debate académico y profesional entre dos filosofías contrapuestas: la gestión activa, que busca superar los rendimientos del mercado mediante estrategias sofisticadas, y la gestión pasiva, que se centra en replicar índices de mercado con costos mínimos. La evidencia empírica acumulada durante más de medio siglo ha demostrado consistentemente la dificultad de la gestión activa para superar estrategias pasivas después de considerar costos y riesgos (Sharpe, 1991). Esta realidad empírica ha consolidado el crecimiento exponencial de la inversión indexada, particularmente a través de Exchange-Traded Funds (ETFs), que han democratizado el acceso a diversificación de bajo costo. Los ETFs representan un caso de estudio particularmente relevante, ya que combinan diversificación inherente con alta liquidez, pero también exhiben correlaciones elevadas que pueden limitar las oportunidades de generación de alpha, especialmente cuando se construyen carteras dentro de un mismo mercado geográfico o sectorial.

En las últimas dos décadas, el desarrollo de técnicas de aprendizaje automático ha renovado las expectativas sobre las capacidades del trading algorítmico para desafiar esta supremacía de la gestión pasiva. Particularmente, el aprendizaje por refuerzo (RL) ha emergido como una aproximación prometedora para la optimización de carteras, al formular la inversión como un problema de toma de decisiones secuenciales bajo incertidumbre (Deng et al., 2016). Los algoritmos de RL han mostrado capacidades notables en dominios complejos como juegos estratégicos y control de sistemas dinámicos, generando expectativas sobre su aplicabilidad en mercados financieros. Sin embargo, los mercados financieros presentan características específicas que plantean desafíos únicos para estos algoritmos: señales débiles con ratios señal-ruido bajos, alta correlación entre activos que reduce el espacio de oportunidades, costos de transacción que penalizan estrategias de alta rotación, y la paradoja fundamental de que el éxito generalizado de cualquier estrategia tiende a arbitrar su propia efectividad a medida que más participantes la adoptan.

Esta investigación aborda la pregunta específica: ¿Puede el algoritmo Soft Actor-Critic (SAC) generar estrategias de inversión que superen consistentemente una cartera equal-weight en un universo de ETFs diversificados? La elección de SAC se fundamenta en su

capacidad demostrada para manejar espacios de acción continuos y su regularización entrópica, que favorece la exploración en entornos con recompensas sparse como los mercados financieros (Haarnoja et al., 2018).

1.2 Objetivos y contribución

El objetivo de este trabajo será el de evaluar empíricamente la capacidad del algoritmo SAC para generar estrategias de optimización de carteras que superen el rendimiento de una estrategia equal-weight pasiva en un universo de ETFs sectoriales estadounidenses. A lo largo de la investigación se ha tratado de:

a) Comparar el impacto de diferentes esquemas de reward shaping: Sharpe ratio puro versus la combinación Sharpe ratio + momentum.

b) Validar la robustez de los resultados mediante análisis multi-seed y walk-forward temporal.

c) Evaluar la estabilidad estadística de cualquier ventaja observada utilizando tests no paramétricos.

d) Identificar las condiciones bajo las cuales el aprendizaje por refuerzo converge a estrategias equivalentes a la gestión pasiva.

La presente investigación aporta evidencia empírica rigurosa sobre los límites del aprendizaje por refuerzo en contextos de optimización de carteras con señales débiles y alta correlación entre activos. Más en concreto, se aporta una metodología robusta que permite evaluar algoritmos de RL en finanzas evitando sesgos como el sobreajuste o el 'data snooping'. Se obtiene evidencia cuantitativa sobre cuándo el algoritmo converge de manera natural a estrategias de gestión pasivas simples, habiéndose establecido previamente una serie de criterios para identificar contextos en los que la complejidad algorítmica adicional no aporta valor económico de manera significativa.

2. Marco teórico y antecedentes

2.1 Optimización de carteras y gestión pasiva

La teoría moderna de carteras, desarrollada por Markowitz en 1952, establece el marco conceptual fundamental para la optimización de inversiones mediante la cuantificación del trade-off entre riesgo y rendimiento esperado. Este enfoque matemático postula que los inversores racionales buscan maximizar el rendimiento esperado para un nivel dado

de riesgo, o minimizar el riesgo para un rendimiento esperado determinado, construyendo así la frontera eficiente de carteras óptimas. Sin embargo, la implementación práctica de la optimización de Markowitz enfrenta limitaciones significativas, particularmente la dependencia de estimaciones precisas de rendimientos esperados, volatilidades y correlaciones, parámetros que son inherentemente inciertos y sujetos a error de estimación (Michaud, 1989). Esta sensibilidad a los inputs ha llevado al desarrollo de estrategias de diversificación alternativas, entre las cuales la cartera equally-weighted emerge como una solución pragmática que asigna pesos uniformes a todos los activos, eliminando la necesidad de estimaciones de parámetros complejas y reduciendo el riesgo de concentración (DeMiguel et al., 2009).

La evidencia empírica acumulada durante más de cinco décadas ha demostrado la dificultad sistemática de las estrategias de gestión activa para superar índices pasivos después de considerar costos de transacción, comisiones de gestión y ajustes por riesgo. El estudio seminal de Jensen (1968) sobre fondos mutuos estadounidenses estableció la base empírica de esta realidad, demostrando que la mayoría de gestores activos no logran generar alpha (α) positivo de manera consistente. Así α representa el rendimiento de una cartera sobre el rendimiento esperado según su nivel de riesgo sistemático, medido típicamente através del modelo CAPM (Capital Asset Pricing Model), donde

$$\alpha = R_p - \left[R_f + \beta * \left(R_m - R_f\right)\right]$$

Siendo R_p el rendimiento de la cartera, R_f la tasa libre de riesgo, β la sensibilidad al mercado, y R_m el rendimiento del mercado. Esta línea de investigación ha sido confirmada y extendida por múltiples estudios, como el ya mencionado Sharpe (1991), que demostró matemáticamente que, en agregado, la gestión activa debe subestimar la gestión pasiva debido a los costos, o como el de Fama y French (2010), que encontraron que muy pocos fondos mutuos generan suficiente α para cubrir sus costos de gestión. La persistencia de esta evidencia empírica ha consolidado el crecimiento exponencial de la inversión indexada, con activos bajo gestión pasiva superando los 1,1 billones de dólares a nivel global (Morningstar, 2025).

2.1.1 Los Exchange-Traded Funds como instrumentos de inversión diversificada

Un Exchange-Traded Fund (ETF) es un fondo de inversión cotizado en bolsa que replica el comportamiento de un índice, sector, materia prima u otro activo subyacente,

combinando la diversificación de un fondo mutuo con la liquidez de negociación de una acción individual (Madhavan, 2016). Los ETFs operan mediante un mecanismo de creación y redención in-kind donde participantes autorizados pueden crear o redimir grandes bloques de acciones (creation units) intercambiando una cesta de valores subyacentes por acciones del ETF. Este proceso de arbitraje mantiene el precio de mercado cerca del valor liquidativo neto (NAV) y minimiza los errores de seguimiento del índice subyacente.

Los ETFs representan la evolución natural de la inversión indexada, combinando las ventajas de diversificación de los fondos mutuos con la liquidez y flexibilidad de negociación de las acciones individuales. Desde la introducción del SPDR S&P 500 ETF (SPY) en 1993, el mercado de ETFs ha experimentado un crecimiento exponencial, alcanzando más de 8,000 productos listados globalmente con activos superiores a los 10 billones de dólares (Investment Company Institute, 2023). Los ETFs sectoriales, en particular, ofrecen exposición diversificada a segmentos específicos de la economía manteniendo costos operativos bajos. Según datos de 2024, el ratio de gastos promedio para ETFs indexados es de 0.48%, mientras que para ETFs activos es de 0.69% con ETFs de mercado amplio que replican el S&P 500 cobrando frecuentemente menos de 0.05% (Fredlick, 2025). Sin embargo, esta especialización sectorial también introduce características que pueden limitar las oportunidades de optimización activa: alta correlación intra-sectorial durante períodos de estrés de mercado, exposición concentrada a factores macroeconómicos específicos, y la paradoja de que la eficiencia inherente de estos instrumentos reduce las ineficiencias explotables por estrategias algorítmicas sofisticadas (Petajisto, 2017).

2.2 Aprendizaje por refuerzo en finanzas

La formulación del trading como problema de decisión secuencial encuentra en el aprendizaje por refuerzo un marco teórico natural y matemáticamente riguroso. En este paradigma, un agente (el algoritmo de trading) interactúa con un entorno (el mercado financiero) observando estados (precios, volúmenes, indicadores técnicos), ejecutando acciones (decisiones de compra, venta o mantenimiento), y recibiendo recompensas (rendimientos, métricas de riesgo-ajustadas) con el objetivo de maximizar la recompensa acumulada esperada a largo plazo (Sutton & Barto, 2018). Esta formulación se modela matemáticamente como un Proceso de Decisión de Markov, donde el estado futuro depende únicamente del estado actual y la acción tomada, asumiendo que toda la

información relevante para la decisión está contenida en el estado presente. En el contexto de gestión de carteras, el espacio de estados típicamente incluye características observables del mercado como precios normalizados, rendimientos históricos, volatilidad realizada e indicadores técnicos, mientras que el espacio de acciones comprende las asignaciones de capital entre activos disponibles, sujetas a restricciones como la suma unitaria de pesos y límites de posición (Jiang et al., 2017).

Las aplicaciones del aprendizaje por refuerzo en gestión de carteras han experimentado un crecimiento significativo en la literatura académica durante la última década, abarcando desde implementaciones de algoritmos clásicos hasta arquitecturas de deep reinforcement learning sofisticadas. Los enfoques iniciales emplearon algoritmos de RL tabular, como Q-learning para espacios de estado discretizados, con resultados mixtos en términos de superación de benchmarks pasivos en las primeras aplicaciones documentadas. La introducción de aproximación de funciones mediante redes neuronales ha permitido el manejo de espacios de estado continuos y de alta dimensionalidad: Deng et al. (2016) aplicaron Deep Q-Networks (DQN) para optimización de carteras multi-activo, mientras que Jiang et al. (2017) desarrollaron el Recurrent Reinforcement Learning framework específicamente para gestión de carteras, incorporando memoria temporal para capturar dependencias secuenciales en datos financieros. Más recientemente, los algoritmos actor-critic han ganado prominencia debido a su capacidad para manejar espacios de acción continuos: Liang et al. (2018) implementaron Proximal Policy Optimization (PPO) para trading de divisas, y Yang et al. (2020) aplicaron Twin Delayed Deep Deterministic Policy Gradient (TD3) para optimización de carteras de acciones, reportando mejoras sobre estrategias buy-and-hold en períodos específicos de prueba.

Sin embargo, la aplicación de RL en finanzas enfrenta limitaciones metodológicas fundamentales que han sido ampliamente documentadas en la literatura crítica. La naturaleza no estacionaria de los mercados financieros viola la asunción de estacionariedad subyacente en la mayoría de algoritmos de RL, donde las distribuciones de recompensas y transiciones de estado cambian continuamente debido a factores macroeconómicos, cambios regulatorios y evolución del comportamiento de participantes del mercado (López de Prado, 2018). La señal débil inherente en datos financieros, caracterizada por ratios señal-ruido bajos y rendimientos que se aproximan a un paseo aleatorio, presenta desafíos adicionales para algoritmos que requieren patrones

consistentes para el aprendizaje efectivo (Harvey et al., 2015). Los problemas de overfitting son particularmente agudos en RL financiero debido al uso intensivo de datos históricos para entrenamiento, lo que puede llevar a estrategias que funcionan bien en backtesting pero fallan en implementación real, un fenómeno conocido como "backtest overfitting" (Bailey et al., 2013). Adicionalmente, la mayoría de estudios académicos en RL financiero adolecen de limitaciones metodológicas críticas: períodos de evaluación limitados, ausencia de costos de transacción realistas, falta de validación out-of-sample robusta, y comparaciones inadecuadas con benchmarks apropiados, lo que cuestiona la validez externa de muchos resultados reportados, especialmente considerando que los trabajos existentes aplicaron métodos de deep reinforcement learning reportando optimistamente incrementos de ganancias en backtesting que pueden sufrir del problema de falsos positivos debido al overfitting (Gort et al., 2022).

3. Metodología: Soft Actor Critic

3.1 Fundamentos teóricos de SAC

Soft Actor-Critic (SAC) es un algoritmo de aprendizaje por refuerzo off-policy que resuelve problemas de control continuo mediante la optimización simultánea de recompensa y entropía (Haarnoja et al., 2018). A diferencia de métodos tradicionales que buscan políticas deterministas, SAC aprende políticas estocásticas que maximizan tanto el retorno esperado como la aleatoriedad de las acciones encontrando una política exitosa en la tarea pero que mantiene la máxima diversidad posible en sus decisiones, resultando en mayor robustez y capacidad de exploración. Los métodos de RL previos presentan limitaciones clave: Los métodos on-policy (PPO, TRPO) son estables pero ineficientes en muestras, los métodos off-policy deterministas (DDPG) son eficientes, pero frágiles e inestables, y los métodos de máxima entropía previos requerían inferencia aproximada compleja. SAC combina la eficiencia de muestras off-policy con la estabilidad de la maximización de entropía, empleando un actor estocástico que extiende el objetivo estándar del RL.

El algoritmo modifica el objetivo tradicional de maximizar la suma esperada de recompensas incorporando un término de entropía, la cual se busca maximizar:

$$J(\pi) = \sum_{t_0}^{T} \mathbb{E}_{s_t,a_t \sim p_\pi}[r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot\,|s_t))] \tag{3.1}$$

Donde α es un parámetro de temperatura, el cual controla el balance exploración-explotación, y $\mathcal{H}(\pi(\cdot|s_t)$ es la entropía de la política, que determina la distribución de probabilidad para la selección de acciones en cada estado.

3.2 Arquitectura de SAC

SAC deriva de la iteración de política suave, que extiende la iteración de política clásica al marco de máxima entropía mediante un proceso alternado de evaluación y mejoramiento. En la fase de evaluación, el algoritmo computa el valor de la política actual según el objetivo de máxima entropía utilizando el operador de Bellman suave:

$$\mathcal{T}^{\pi}Q(s_t, a_t) \triangleq r(s_t, a_t) + \gamma \mathbb{E}_{s(t+1)\sim\rho}[V(s_{t+1})] \tag{3.2}$$

donde la función de valor de estado suave se define como:

$$V(s_t) = \mathbb{E}_{a_t\sim\pi}[Q(s_t, a_t) - \alpha log\pi(a_t|s_t) \tag{3.2}$$

En la fase de mejoramiento, la política se actualiza hacia la exponencial de la función Q mediante minimización de divergencia KL, proyectando la nueva política al conjunto de políticas factibles. Esta iteración converge a la política óptima de máxima entropía, garantizando mejora monótona del valor.

Para implementación práctica en espacios continuos, SAC emplea tres componentes neurales: un actor estocástico $\pi_{\phi}(a_t|s_t)$ parametrizado como distribución gaussiana, dos críticos gemelos $Q_{\theta_1}, Q_{\theta_2}$ para mitigar sobreestimación de valores Q, y redes objetivo con actualización de media móvil exponencial para estabilizar el entrenamiento. El ajuste automático de temperatura α elimina la necesidad de tuning manual, adaptando dinámicamente el balance exploración-explotación durante el entrenamiento mediante optimización dual con restricción de entropía mínima.

3.3 Implementación técnica de SAC para trading

SAC funciona como un trader que aprende por experiencia, pero con tres "cerebros" especializados trabajando simultáneamente. El primer cerebro es el actor, que decide qué hacer. Dado el estado actual del mercado (precios, tendencias), propone cómo distribuir el dinero entre los distintos activos que componen el entorno. A diferencia de un trader determinista que siempre tomaría la misma decisión en la misma situación, el actor de SAC introduce aleatoriedad controlada, es decir, puede decidir poner 40% o 45% en un mismo activo, manteniendo diversidad en sus decisiones.

Los otros dos cerebros son los críticos, que evalúan qué tan buena es cada decisión posible. Funcionan como asesores independientes que estiman: "si pones X% en cada activo, ¿cuánto ganarás a largo plazo?". Tener dos críticos evita el exceso de optimismo, de manera que cuando uno dice "esta decisión dará mucho dinero", el otro puede ser más conservador, y el algoritmo toma la estimación más prudente.

El proceso de aprendizaje simula años de experiencia en minutos: el actor prueba diferentes distribuciones de dinero, observa los resultados (ganancias o pérdidas), y los críticos van refinando sus evaluaciones. Simultáneamente, el actor mejora sus decisiones para elegir distribuciones que los críticos consideren prometedoras, pero manteniendo suficiente exploración para no quedarse atascado en una sola estrategia. Un mecanismo automático ajusta el balance entre "explorar nuevas ideas" y "explotar lo que ya sabemos que funciona", eliminando la necesidad de ajustes manuales complejos y permitiendo que el algoritmo se adapte a diferentes condiciones de mercado.

4. Diseño experimental

4.1 Datos y universo de inversión

El universo de inversión comprende cuatro ETFs sectoriales estadounidenses seleccionados por su representatividad y liquidez: SPDR S&P 500 ETF Trust (SPY), que replica el índice S&P 500; Invesco QQQ Trust (QQQ), centrado en el sector tecnológico del NASDAQ-100; Energy Select Sector SPDR Fund (XLE), que proporciona exposición al sector energético; y Financial Select Sector SPDR Fund (XLF), enfocado en el sector financiero. Los datos históricos diarios abarcan desde el 10 de marzo de 1999 hasta junio de 2025, lo que proporciona un período de análisis de más de 26 años con 6,555 observaciones.

La división temporal sigue una estructura estricta sin solapamiento para evitar data leakage: el conjunto de entrenamiento incluye datos hasta el 31 de diciembre de 2019, el conjunto de test comprende el período del 1 de enero de 2020 al 31 de diciembre de 2022, y el conjunto de holdout abarca desde el 1 de enero de 2023 hasta el final de la muestra. Esta división temporal permite evaluar el rendimiento de los modelos durante diferentes regímenes de mercado, incluyendo la crisis de COVID-19 en el conjunto de test y el período de normalización posterior en holdout.

El preprocesamiento de datos emplea *StandardScaler* exclusivamente ajustado con datos de entrenamiento para evitar data leakage, aplicando posteriormente la misma transformación a los conjuntos de test y holdout. El espacio de características incluye no solo los precios escalados de los ETFs, sino también indicadores técnicos como momentum de 5, 20 y 60 días, volatilidad realizada de 20 días, medias móviles simples de 20 y 50 días, una variable de tendencia binaria que compara SMA20 y SMA50, y el índice de fuerza relativa (RSI) para cada ETF. Adicionalmente, se incorporan variables macroeconómicas como el VIX y el tipo de interés de la FED, proporcionando contexto sobre condiciones de mercado y política monetaria.

4.2 Configuración del entorno de trading

El espacio de observaciones integra todos los datos escalados en un vector de 41 dimensiones, incluyendo precios normalizados de los ETFs, indicadores técnicos individuales y variables macroeconómicas. Esta representación multidimensional permite al algoritmo SAC capturar relaciones complejas entre diferentes fuentes de información financiera y condiciones de mercado. El escalado mediante z-score sobre ventanas móviles de 252 días normaliza las series temporales eliminando sesgos de escala entre activos y facilitando la convergencia del algoritmo.

El espacio de acciones se define como los pesos de $w_t = [w_1, w_2, w_3, w_4]$ para los cuatro ETFs, con restricciones fundamentales $\sum_{i=1}^{4} w_i = 1$ y $w_i \in [0,1]$, excluyendo ventas en corto. La implementación emplea transformación softmax de las salidas del actor para garantizar automáticamente el cumplimiento de estas restricciones: $w_i = \frac{\exp(a_i)}{\sum_{i=1}^{4} \exp(a_j)}$, donde a_i representa las salidas brutas de la red neuronal.

4.3 Estrategias de reward shaping

La diferenciación entre fases se basa en esquemas de reward shaping específicamente diseñados para evaluar el impacto de señales adicionales en el aprendizaje. La Fase 3A emplea exclusivamente Sharpe ratio como señal de optimización, calculado como $r_t = \frac{\mu_{portfolio}}{\sigma_{portfolio}}$ sobre ventanas móviles de 20 días de rendimientos de cartera. Esta configuración establece la línea base para evaluar el aprendizaje con una única métrica de riesgo-ajustado ampliamente reconocida.

La Fase 3C incorpora momentum como factor adicional mediante una combinación ponderada: $r_t = 0.6 * SharpeRatio + 0.4 * MomentumSignal$, donde el momentum se mide como la suma de rendimientos acumulados de 30 días, normalizada por la volatilidad del período y suavizada mediante función tangente hiperbólica para evitar valores extremos. La ponderación 60/40 entre Sharpe y momentum refleja el balance entre optimización de riesgo-ajustado y aprovechamiento de tendencias de precios, permitiendo evaluar si la incorporación de factores quantitativos tradicionales mejora el aprendizaje en contextos de señal débil.

La evaluación implementa una separación crítica entre entrenamiento y validación. Durante el entrenamiento, los modelos reciben rewards con shaping según su fase correspondiente, mientras que la evaluación emplea únicamente rendimientos absolutos de cartera sin ningún shaping adicional. Esta metodología elimina sesgos en la comparación con benchmarks pasivos y proporciona una medida objetiva del rendimiento real de las estrategias aprendidas.

5. Resultados principales

5.1 Validación multi-seed

La validación de robustez mediante múltiples semillas independientes constituye un elemento crítico para evaluar la estabilidad y reproducibilidad de los algoritmos de aprendizaje por refuerzo en contextos financieros. Se entrenaron ambas fases utilizando tres semillas aleatorias independientes (42, 123, 456), completando cada entrenamiento con 150,000 timesteps para garantizar convergencia estable sin sobreentrenamiento. Toda la información se puede contrastar en las figuras 1, 2 y 3 del anexo I.

Los resultados en el conjunto de holdout demuestran una consistencia excepcional entre semillas. La Fase 3A alcanzó un Sharpe ratio promedio de 0.0717 ± 0.0001, con un coeficiente de variación de apenas 0.001, mientras que la Fase 3C obtuvo 0.0720 ± 0.0004 con coeficiente de variación de 0.006. Estas desviaciones estándar microscópicas confirman que ambos algoritmos convergen de manera determinística hacia estrategias estables, independientemente de la inicialización aleatoria de los pesos de las redes neuronales.

La diferencia media entre ambas fases resulta estadísticamente insignificante, con un p-valor de 0.4764 en el t-test pareado. El test de Wilcoxon confirma esta ausencia de

diferencia significativa. Aunque el Cohen's d de -0.769 sugiere un tamaño de efecto mediano en términos absolutos, la magnitud de la diferencia (0.0003 en la ratio de Sharpe) carece de relevancia económica práctica. Las curvas de evolución del entrenamiento muestran convergencia rápida alrededor de los 60,000 timesteps, con bandas de confianza extremadamente estrechas que indican estabilidad del proceso de aprendizaje.

Las métricas adicionales corroboran la equivalencia entre fases: rendimiento total (3A: 0.4035 ± 0.0004, 3C: 0.4049 ± 0.0025), máximo drawdown (3A: -0.1895 ± 0.0000, 3C: -0.1877 ± 0.0025), y volatilidad idéntica (0.1597 ± 0.0000 para ambas fases). La alta consistencia multi-seed y la ausencia de diferencias estadísticamente significativas proporcionan evidencia sólida de que ambos algoritmos convergen hacia la misma estrategia subyacente, sugiriendo que el reward shaping adicional con momentum no aporta ventaja discernible en este contexto de optimización de carteras con ETFs correlacionados.

5.2 Comparación directa con equal-weight

La evaluación objetiva del modelo SAC Fase 3A frente al benchmark equal-weight, como puede observarse en la figura 4 del anexo I, revela una equivalencia estadística prácticamente perfecta en ambos conjuntos de datos. En el conjunto de test (2020-2022), el modelo 3A alcanzó un Sharpe ratio de 0.0740 frente a 0.0741 del equal-weight, una diferencia de apenas -0.0001. Las métricas complementarias confirman esta convergencia: rendimiento total de 0.7436 frente a 0.7447, máximo drawdown de -0.1892 frente a -0.1890), y volatilidad de 0.2295 frente a 0.2296, muestran diferencias microscópicas sin relevancia económica.

El conjunto de holdout replica estos resultados con precisión notable: La Sharpe ratio del modelo (0.0788) contra el del equal-weight (0.0787) tiene una diferencia de +0.0001. Los rendimientos totales (0.4432 vs 0.4428), drawdowns idénticos (-0.1831), y volatilidades equivalentes (0.1595) demuestran que el algoritmo SAC converge hacia la estrategia equal-weight como solución óptima. El turnover de ambas estrategias es cero, confirmando que el modelo aprendido mantiene pesos constantes idénticos a la estrategia pasiva.

Los tests estadísticos formales confirman la ausencia de diferencias significativas. En el conjunto de test, el t-test produce un p-valor de 0.0709 y el test de Wilcoxon 0.2219, ambos superiores a 0.05. En holdout, los p-valores son 0.2027 y 0.1457 respectivamente.

Los valores de Cohen's d indican tamaños de efecto nulos, mientras que las diferencias medias carecen de significancia tanto estadística como económica. Las curvas de valor acumulado se superponen completamente en ambos períodos, proporcionando evidencia visual inequívoca de la equivalencia práctica entre ambas estrategias.

5.3 Análisis walk-forward

El análisis walk-forward, cuyos resultados se pueden observar en las figuras 5 y 6 del anexo I, evalúa la estabilidad temporal de la equivalencia modelo-benchmark mediante ventanas deslizantes de diferente granularidad. El análisis anual, empleando ventanas de 12 meses con pasos de 3 meses, abarca 5 períodos temporales consecutivos y revela una diferencia media de Sharpe de 0.000098 ± 0.000039, con diferencia máxima observada de 0.000163. El modelo supera al benchmark en el 100% de los períodos anuales, aunque las magnitudes de superación son económicamente irrelevantes.

El análisis semestral, con ventanas de 6 meses y pasos de 2 meses cubriendo 11 períodos, confirma la estabilidad de la equivalencia con diferencia media de 0.000079 ± 0.000078. En esta granularidad temporal más fina, el modelo supera al benchmark en 81.8% de los períodos, con diferencia máxima de 0.000191. Los coeficientes de variación son prácticamente idénticos entre escalas temporales, 0.323 en ambos casos para análisis anual, y 0.610 vs 0.610 para análisis semestral, indicando estabilidad inherente equivalente.

La distribución de diferencias se centra en cero con media 0.0001, confirmando que las desviaciones observadas son puramente aleatorias sin patrón sistemático. Los coeficientes de autocorrelación de las diferencias (-0.275 anual, -0.001 semestral) indican ausencia de tendencias temporales, mientras que la consistencia entre escalas temporales (diferencia anual 0.000098 vs semestral 0.000079) demuestra robustez del resultado. El análisis walk-forward proporciona evidencia convincente de que la equivalencia estadística se mantiene estable a través del tiempo, confirmando que SAC converge de manera consistente hacia la estrategia equal-weight independientemente del régimen de mercado o período de evaluación.

6. Interpretación de los resultados

6.1 Convergencia a estrategia pasiva

Los resultados experimentales revelan un hallazgo académicamente significativo: el algoritmo SAC converge sistemáticamente hacia la estrategia equal-weight como solución óptima en el contexto de optimización de carteras con ETFs diversificados. Esta convergencia no representa una limitación del algoritmo, sino una validación de su capacidad para identificar correctamente la ausencia de alpha explotable en mercados eficientes. La equivalencia estadística observada entre las estrategias aprendidas y el benchmark equal-weight, con diferencias de Sharpe ratio del orden de 0.0001, demuestra que SAC ha encontrado la frontera óptima de riesgo-rendimiento disponible en el universo de activos analizado.

La convergencia hacia equal-weight refleja las características estructurales del universo de inversión empleado. Los ETFs sectoriales analizados exhiben correlaciones elevadas durante períodos de estrés sistémico, limitando los beneficios de diversificación dinámica que podrían explotar algoritmos más sofisticados. La evidencia empírica confirma que, en ausencia de ineficiencias persistentes o factores de riesgo no capturados por la estrategia equal-weight, los algoritmos de aprendizaje por refuerzo convergen naturalmente hacia soluciones de diversificación naïve que han demostrado robustez empírica en múltiples contextos académicos (DeMiguel et al., 2009).

El fracaso del reward shaping adicional con momentum en generar ventajas discernibles sugiere que las señales de momentum tradicionales no proporcionan información incremental valiosa en el horizonte temporal diario analizado. Esta observación es consistente con la literatura sobre eficiencia de mercados en instrumentos altamente líquidos como los ETFs principales, donde las oportunidades de arbitraje se eliminan rápidamente por la actividad de market makers y arbitrajistas institucionales. La validación multi-seed confirma que esta convergencia es robusta a diferentes inicializaciones aleatorias, indicando que representa una propiedad fundamental del espacio de optimización rather que un artefacto del proceso de entrenamiento.

6.2 Implicaciones para el trading algorítmico

Los resultados obtenidos proporcionan evidencia empírica sobre las limitaciones inherentes del aprendizaje por refuerzo en contextos financieros caracterizados por alta correlación entre activos y señales débiles. La capacidad de SAC para converger hacia estrategias pasivas óptimas, documentada mediante análisis walk-forward temporal, sugiere que estos algoritmos pueden servir como herramientas de validación para evaluar

la existencia de alpha explotable en universos de inversión específicos. Cuando algoritmos sofisticados convergen hacia estrategias naïve, esto constituye evidencia de eficiencia de mercado y ausencia de patrones explotables persistentes.

Las implicaciones metodológicas trascienden el caso específico analizado. El framework experimental empleado, que separa rigurosamente el reward shaping durante entrenamiento de la evaluación objetiva sin shaping, proporciona un protocolo replicable para evaluar estrategias de trading algorítmico evitando sesgos de optimización in-sample. La validación multi-seed y el análisis walk-forward temporal establecen estándares mínimos de robustez que deberían aplicarse sistemáticamente en la literatura de RL financiero para mitigar el problema de publication bias hacia resultados positivos.

Los hallazgos sugieren criterios específicos para identificar contextos donde la complejidad algorítmica adicional no está justificada. Universos de activos con correlaciones superiores a 0.7, instrumentos con spreads bid-ask estrechos y alta actividad de arbitraje institucional, y horizontes temporales donde predominan componentes de ruido sobre señales predictivas, constituyen entornos donde estrategias simples de diversificación pueden superar aproximaciones más sofisticadas después de considerar costos de implementación y riesgos operacionales. Esta perspectiva revalida la sabiduría de Bogle sobre la superioridad de estrategias de inversión de bajo costo en mercados eficientes, ahora confirmada mediante herramientas de inteligencia artificial contemporáneas.

7. Limitaciones y trabajo futuro

Este estudio presenta limitaciones metodológicas y conceptuales importantes que deben considerarse al interpretar los resultados y que delimitan el alcance de las conclusiones obtenidas. El universo de inversión limitado a cuatro ETFs sectoriales estadounidenses, aunque metodológicamente apropiado para evaluar la hipótesis central sobre convergencia hacia estrategias pasivas, restringe significativamente la generalización de los hallazgos. Los ETFs analizados presentan características específicas que pueden haber influido en los resultados: alta liquidez que facilita eficiencia de precios, correlaciones estructuralmente elevadas debido a su exposición al mercado estadounidense, y spreads bid-ask mínimos que reducen las oportunidades de arbitraje estadístico. Esta selección, si bien representativa de instrumentos ampliamente utilizados en gestión institucional, no captura la heterogeneidad de oportunidades disponibles en universos más diversos que

incluyan activos internacionales, materias primas, o instrumentos de renta fija con diferentes perfiles de riesgo-duración.

El horizonte temporal exclusivamente diario constituye una limitación fundamental dado que numerosas anomalías de mercado documentadas en la literatura académica se manifiestan en frecuencias menores donde el ruido microestructural es menos dominante. La evidencia empírica sugiere que estrategias de momentum y reversión a la media operan más efectivamente en horizontes semanales o mensuales, donde las señales fundamentales pueden superar el componente aleatorio que caracteriza fluctuaciones diarias en mercados líquidos. Adicionalmente, la ausencia de costos de transacción variables y slippage realista puede haber subestimado las ventajas de estrategias de baja rotación como equal-weight frente a enfoques más dinámicos que requieren rebalanceos frecuentes.

El período temporal analizado incluye múltiples regímenes de mercado distintivos, desde crisis tecnológicas hasta expansión cuantitativa y pandemia global, pero el modelo carece de variables de régimen explícitas que permitan una adaptación correcta a esos contextos cambiantes. Esta limitación puede haber impedido al algoritmo identificar períodos específicos donde estrategias activas históricamente han superado enfoques pasivos, como transiciones entre mercados alcistas y bajistas o períodos de alta dispersión sectorial. La arquitectura de red neuronal empleada, aunque estándar para aplicaciones SAC, no incorpora mecanismos de memoria a largo plazo o atención temporal que podrían capturar dependencias complejas en series financieras.

Las extensiones futuras más prometedoras abarcan múltiples dimensiones metodológicas y empíricas. La incorporación de variables de régimen macroeconómico como el VIX, spreads de crédito, pendiente de la curva de tipos, e indicadores de flujos de capital institucional podría permitir al algoritmo identificar períodos donde estrategias activas justifican su complejidad adicional. La exploración sistemática de frecuencias temporales alternativas, particularmente horizontes semanales y mensuales donde señales fundamentales pueden dominar ruido de alta frecuencia, representa una línea de investigación natural que podría revelar contextos temporales más favorables para RL.

El análisis de universos internacionales con menor correlación estructural constituye una extensión crítica, dado que mercados emergentes, REITs globales, y commodities pueden ofrecer oportunidades de diversificación dinámica no evidentes en ETFs sectoriales

domésticos. La implementación de técnicas de ensemble learning combinando múltiples algoritmos de RL (SAC, PPO, TD3) podría revelar si la convergencia hacia estrategias pasivas es específica de SAC o representa una propiedad más general de aproximaciones de aprendizaje por refuerzo en contextos de señal débil.

Particularmente relevante sería el desarrollo de métricas de "detectabilidad de alpha" que permitan a priori identificar universos de inversión donde algoritmos complejos tienen probabilidades razonables de superar estrategias naïve. Finalmente, la aplicación de técnicas de transfer learning entre diferentes universos de activos y períodos temporales podría contribuir a una teoría más general sobre las condiciones bajo las cuales la inteligencia artificial añade valor genuino en gestión de inversiones, versus contextos donde la complejidad adicional simplemente introduce riesgos operacionales sin beneficios compensatorios.

8. Conclusiones

La presente investigación proporciona evidencia empírica rigurosa sobre los límites del aprendizaje por refuerzo en contextos de optimización de carteras caracterizados por alta correlación entre activos y señales débiles. El algoritmo Soft Actor-Critic converge sistemáticamente hacia la estrategia equal-weight en un universo de ETFs sectoriales estadounidenses, demostrando una equivalencia estadística prácticamente perfecta con diferencias de Sharpe ratio del orden de 0.0001. Esta convergencia no representa una limitación del algoritmo, sino una validación de su capacidad para identificar correctamente la ausencia de alpha explotable en el universo de inversión analizado.

La validación multi-seed confirma la robustez de estos resultados, con coeficientes de variación microscópicos (0.001-0.006) que demuestran convergencia determinística independiente de la inicialización aleatoria. El análisis walk-forward temporal, abarcando múltiples ventanas deslizantes anuales y semestrales, establece que la equivalencia se mantiene estable a través de diferentes regímenes de mercado, desde la crisis de COVID-19 hasta períodos de normalización posterior. Los tests estadísticos formales (t-test, Wilcoxon) producen p-valores superiores a 0.05 en todos los casos, confirmando la ausencia de diferencias estadísticamente significativas. El fracaso del reward shaping adicional con momentum en generar ventajas discernibles sugiere que las señales técnicas tradicionales no proporcionan información incremental valiosa en horizontes temporales diarios con instrumentos altamente líquidos. Esta observación refuerza la hipótesis de

eficiencia de mercado en ETFs principales, donde las oportunidades de arbitraje se eliminan rápidamente por la actividad institucional. La metodología experimental empleada, que separa rigurosamente el reward shaping durante entrenamiento de la evaluación objetiva, proporciona un protocolo replicable para evaluar estrategias de trading algorítmico evitando sesgos de optimización in-sample.

Los hallazgos contribuyen a la literatura académica validando algorítmicamente la sabiduría de estrategias de inversión pasiva en contextos específicos. Cuando algoritmos sofisticados de inteligencia artificial convergen hacia estrategias naïve, esto constituye evidencia robusta de que la complejidad adicional no está justificada después de considerar costos de implementación y riesgos operacionales. El resultado académico más significativo radica en demostrar que los algoritmos de RL, aplicados correctamente, pueden servir como herramientas de validación para evaluar la existencia de alpha explotable, confirmando mediante técnicas contemporáneas principios fundamentales de la teoría de mercados eficientes establecidos por Bogle y la literatura de gestión pasiva.

Bibliografía

1. Bailey, D. H., Borwein, J., De Prado, M. L., & Zhu, Q. J. (2013). The probability of Back-Test Over-Fitting. *SSRN Electronic Journal*. https://doi.org/10.2139/ssrn.2326253

2. DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies, 22*(5), 1915-1953. https://doi.org/10.1093/rfs/hhm075

3. Deng, Y., Bao, F., Kong, Y., Ren, Z. and Dai, Q., "Deep Direct Reinforcement Learning for Financial Signal Representation and Trading,". (2017, March). IEEE Journals & Magazine | IEEE Xplore. https://ieeexplore.ieee.org/document/7407387

4. Fama, E. F., & French, K. R. (2010). Luck versus skill in the cross-section of mutual fund returns. *The Journal of Finance, 65*(5), 1915-1947. https://doi.org/10.1111/j.1540-6261.2010.01598.x

5. Fredlick, E. (2025, July 21). *Morningstar's Guide to ETF Investing*. Morningstar, Inc. https://www.morningstar.com/funds/morningstars-guide-etf-investing

6. Gort, B. J. D., Liu, X., Sun, X., Gao, J., Chen, S., & Wang, C. D. (2022). Deep Reinforcement Learning for Cryptocurrency Trading: Practical approach to address backtest Overfitting. *arXiv (Cornell University)*. https://doi.org/10.48550/arxiv.2209.05559

7. Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018, January 4). *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor*. arXiv.org. https://arxiv.org/abs/1801.01290

8. Harvey, C. R., Liu, Y., & Zhu, H. (2015). . . . and the Cross-Section of expected returns. *Review of Financial Studies*, *29*(1), 5–68. https://doi.org/10.1093/rfs/hhv059

9. Investment Company Institute. (2023). *2023 Investment Company Fact Book: A review of trends and activities in the investment company industry* (63rd ed.). Investment Company Institute. https://www.ici.org/system/files/2023-05/2023-factbook.pdf

10. Jensen, M. C. (1968). The performance of mutual funds in the period 1945-1964. *The Journal of Finance, 23*(2), 389-416. https://doi.org/10.1111/j.1540-6261.1968.tb00815.x

11. Jiang, Z., Xu, D., & Liang, J. (2017, June 30). *A deep reinforcement learning framework for the Financial Portfolio Management problem*. arXiv.org. https://arxiv.org/abs/1706.10059

12. Liang, Z., Chen, H., Zhu, J., Jiang, K., & Li, Y. (2018, August 29). *Adversarial deep reinforcement learning in portfolio management*. arXiv.org. https://arxiv.org/abs/1808.09940

13. Lopez de Prado, M. (2018). *Advances in financial machine learning*. John Wiley & Sons.

14. Madhavan, A. N. (2016). Exchange-Traded funds and the new dynamics of investing. *ideas.repec.org*. https://ideas.repec.org/b/oxp/obooks/9780190279394.html

15. Markowitz, H. (1952). Portfolio selection. *The Journal of Finance, 7*(1), 77-91. https://doi.org/10.1111/j.1540-6261.1952.tb01525.x

16. Michaud, R. O. (1989). The Markowitz optimization enigma: Is 'optimized' optimal? *Financial Analysts Journal, 45*(1), 31-42. https://doi.org/10.2469/faj.v45.n1.31

17. Morningstar, Inc. (2025, January 16). *Global Fund Flows Annual data*. https://www.morningstar.com/business/insights/blog/funds/global-fund-flows

18. Petajisto, A. (2017). Inefficiencies in the pricing of Exchange-Traded funds. *ideas.repec.org*. https://ideas.repec.org/a/taf/ufajxx/v73y2017i1p24-54.html

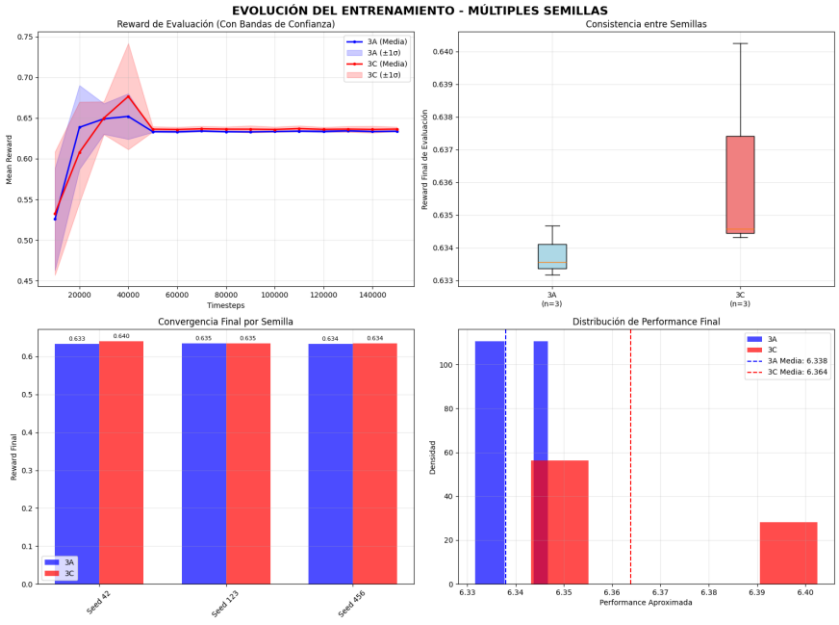
19. Sharpe, W. F. (1991). The arithmetic of active management. *Financial Analysts Journal, 47*(1), 7-9. https://doi.org/10.2469/faj.v47.n1.7

20. Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd ed.). MIT Press.

21. Yang, H., Liu, X., Zhong, S., & Walid, A. (2020). Deep Reinforcement Learning for Automated Stock Trading: An Ensemble Strategy. *SSRN Electronic Journal*. https://doi.org/10.2139/ssrn.3690996

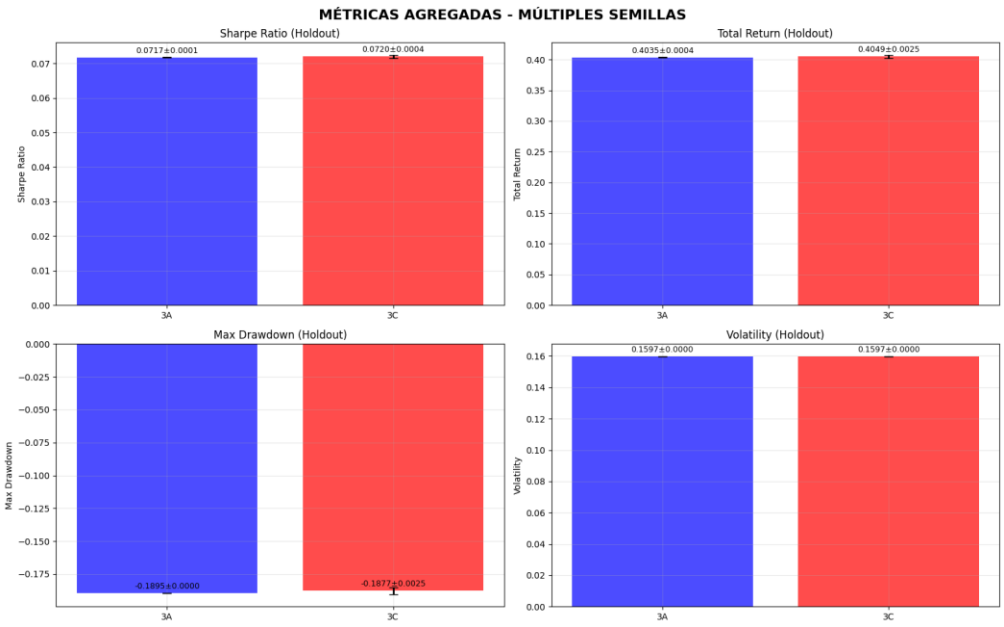
ANEXO

Figura 1: Evolución del entrenamiento multisemilla



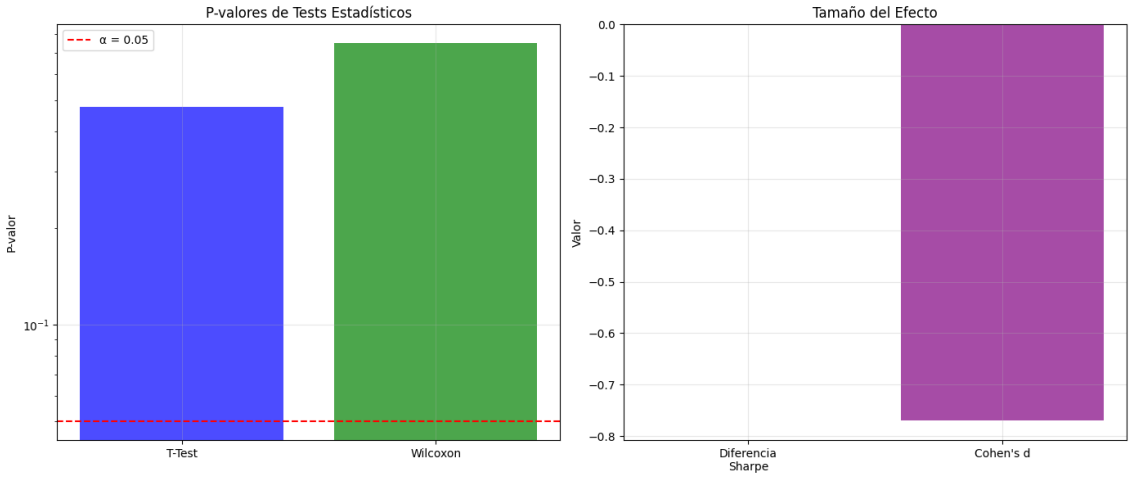
Fuente: Elaboración propia

Figura 2: Métricas del entrenamiento multisemilla



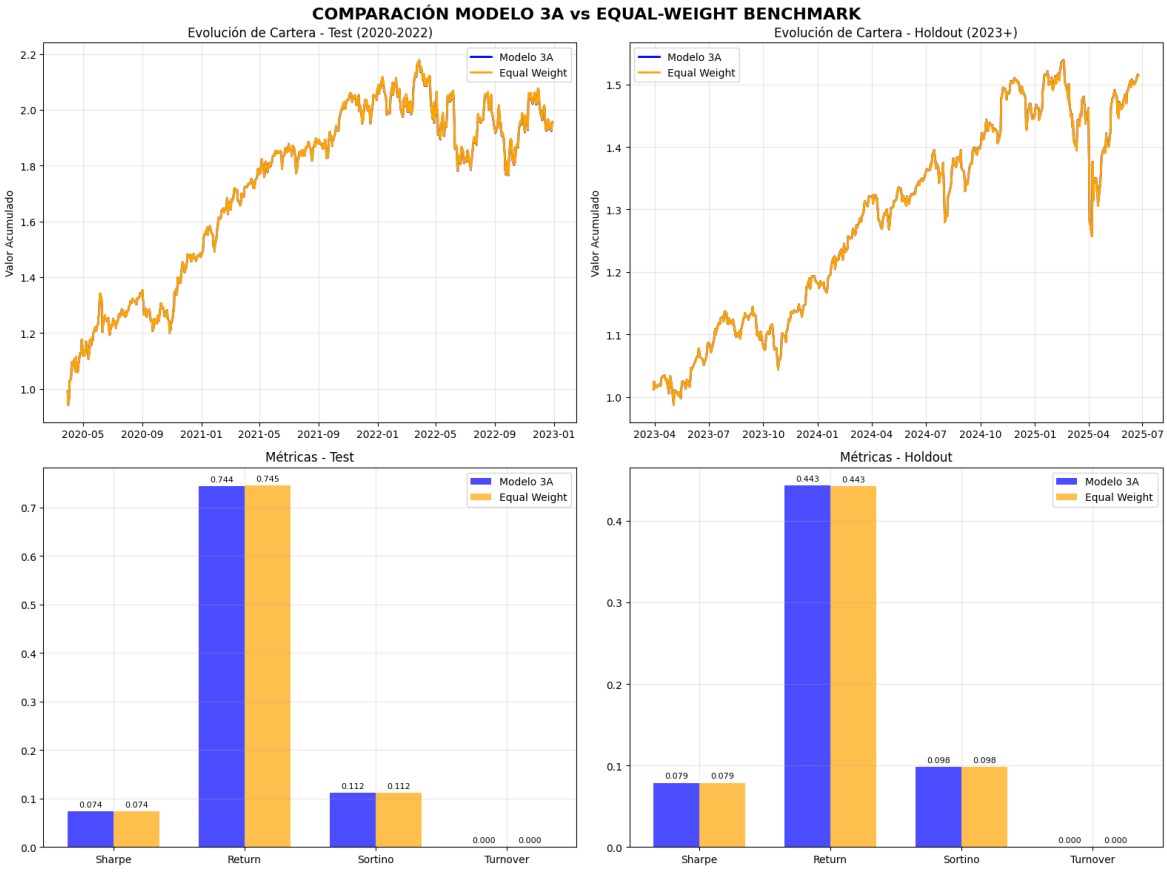
Fuente: Elaboración propia

Figura 3: Valores estadísticos del entrenamiento multisemilla



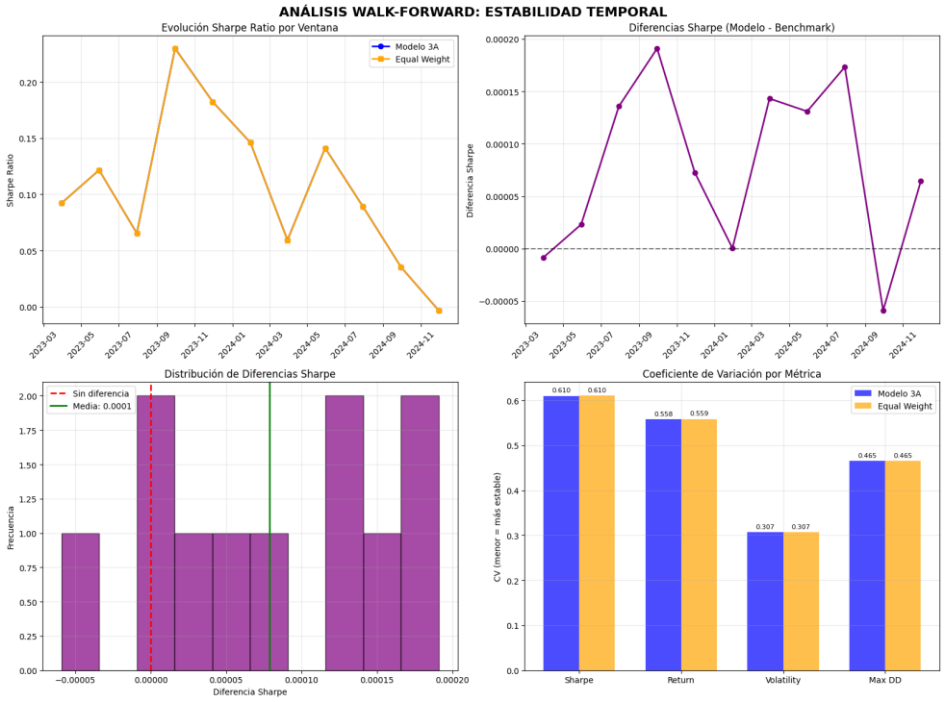
Fuente: Elaboración propia

Figura 4: Modelo 3A vs Estrategia Equal-Weight



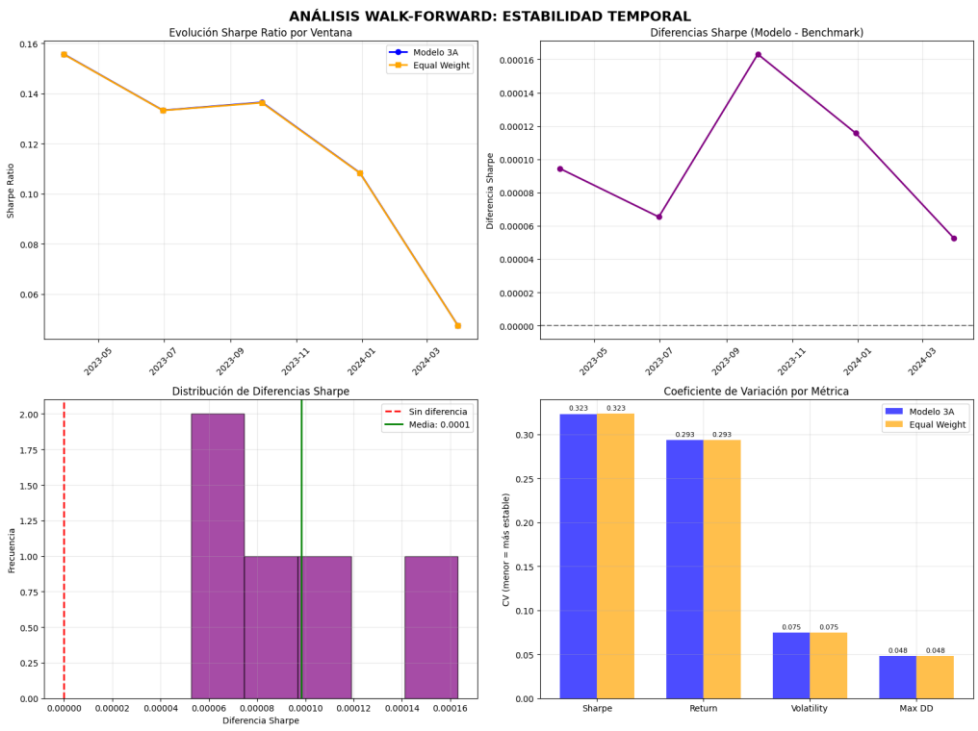
Fuente: Elaboración propia

Figura 5: Análisis Walk-Forward I



Fuente: Elaboración propia

Figura 6: Análisis Walk-Forward II



Fuente: Elaboración propia

Santiago Calvo López

Tutor del TFM

Universidad de las Hespérides

30/09/2025

A la atención del Coordinador de TFM,

Prof. Santiago Dussan

Coordinador Académico de TFM

Universidad de las Hespérides

Estimado Prof. Santiago Dussan,

Por medio de la presente, y en mi calidad de tutor del Trabajo Fin de Máster (TFM), quisiera informarle que el/la estudiante Fernando de Rojas Ojeda, inscrito/a en el Máster en Economía, ha completado su TFM titulado “Los límites del Aprendizaje por Refuerzo en Finanzas: Convergencia hacia Estrategias Equal-Weight en Carteras de ETFs”.

Después del acompañamiento que he adelantado al estudiante en su proceso de composición del TFM, creo que cumple con los requisitos académicos y científicos exigidos para este tipo de trabajos, y por lo tanto, doy mi visto bueno para que la versión final del texto sea presentado por el estudiante, de tal manera que comience el proceso de evaluación del mismo.

Quedo a la espera de su respuesta y a disposición para cualquier aclaración adicional que sea necesaria.

Atentamente,

Firma del tutor:

CALVO LOPEZ SANTIAGO - 34271771T

Firmado digitalmente por CALVO LOPEZ SANTIAGO - 34271771T
Fecha: 2025.09.30 18:15:06 +02'00'

Santiago Calvo López

Profesor

Universidad de las Hespérides